Üzleti Intelligencia

3. Előadás: Markov döntési folyamatok megoldása

Kuknyó Dániel
Budapesti Gazdasági Egyetem

2023/24
1.félév

Az RL modellje

Markov döntési folyamat

$$MDP\,(S, A, P, R, s_0, \gamma)$$

- S: állapotok halmaza
- A: cselekvések halmaza
- $P: \ S \times A \times S \rightarrow [0,1]$: állapotátmeneti valószínűségek
- $R: \ S \times A \rightarrow \mathbb{R}$: azonnali jutalmak
- s_0: kezdőállapot
- γ: diszkont faktor

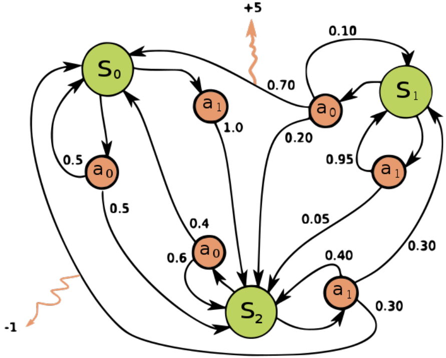

Az RL modellje

Az MDP folyamata:

1. Az ügynök s_0 állapotból indul
2. Az ügynök π politika szerint cselekszik: $a_t \sim \pi(s_t)$
3. A környezet reagál a cselekvésre, és visszaadja az ügynöknek r_{t+1} jutalmat és s_{t+1} következő állapotot
4. Ez ismétlődik amíg a kilépési kritérium be nem teljesül

Cél: Az optimális politika megtalálása. A politika optimális, ha a hozamának várható értéke maximális:

$$E_\pi\left(r_1 + \gamma r_2 + \gamma^2 r_3 + ...\right) \rightarrow max$$

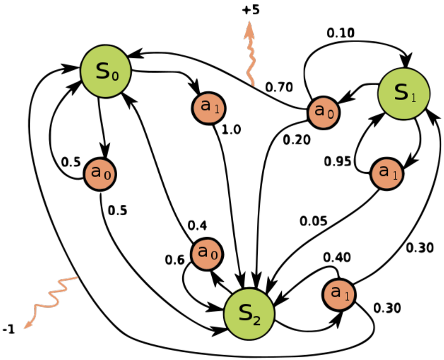

A mohó ügynök

A legegyszerűbb cselekvés kiválasztási szabály, ha az ügynök mindig azt a cselekvést választja, ami számára a lehető legnagyobb várható hozammal rendelkezik.

Mohó cselekvés választás

Mohó politika mindig azt a cselekvést fogja választani, amelyik - egy lépéses távlatban - a lehető legnagyobb várható jutalommal fog járni az ügynök számára v_π szerint.

$$A_t = \underset{a}{argmax}\, Q_t(a)$$

- Mi lenne a mohó politika ebben az estben?
- Mindig ez a legjobb megoldás?
- A legjobb megoldás mindig mohó?

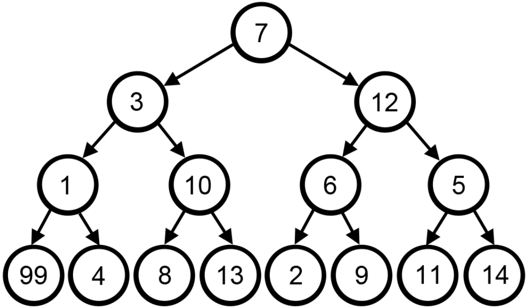

A mohó ügynök

A legegyszerűbb cselekvés kiválasztási szabály, ha az ügynök mindig azt a cselekvést választja, ami számára a lehető legnagyobb várható hozammal rendelkezik.

Mohó cselekvés választás

Mohó politika mindig azt a cselekvést fogja választani, amelyik - egy lépéses távlatban - a lehető legnagyobb várható jutalommal fog járni az ügynök számára v_π szerint.

$$A_t = \underset{a}{argmax}\, Q_t(a)$$

- Mi lenne a mohó politika ebben az estben?
- Mindig ez a legjobb megoldás?
- A legjobb megoldás mindig mohó?

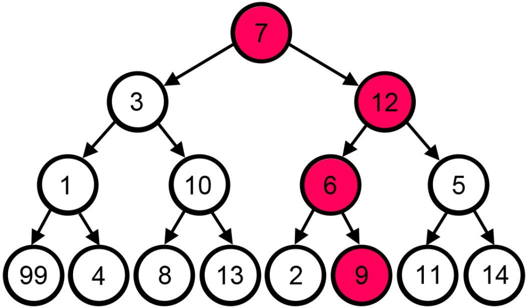

Az ε-mohó stratégia

Egy másik lehetőség, ha adott valószínűséggel az ügynök véletlen cselekvést hajt végre remélve, hogy ezzel elér egy olyan állapotba amelyhez nagy jutalom tartozik. A véletlen cselekvés a **felfedezés**, és végrehajtásának valószínűsége ϵ.

ε-mohó cselekvés választás

$$A_t \leftarrow \begin{cases} \underset{a}{argmax} Q(a) & P{=}1{-}\varepsilon \\ a{\sim}A & P{=}\varepsilon \end{cases}$$

Az ügynök tehát ε valószínűséggel véletlen cselekvést választ az ismeretlen, de nagyobb jutalom reményében. Ez a **felfedezés** művelete.
ε valószínűséggel pedig a már ismert és a legnagyobb várható jutalommal járó cselekvést hajtja végre. Ez a **kizsákmányolás** művelete.

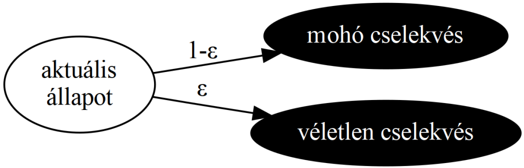

Példák

A következő valós példák alkalmasak a felfedezés/kizsákmányolás dilemma bemutatására:

- Étterem választás:
  - **Kizsákmányolás**: elmész a kedvenc éttermedbe.
  - **Felfedezés**: elmész egy új étterembe, hátha találsz egy jobbat mint a kedvenced.
- Online hirdetés:
  - **Kizsákmányolás**: a legjobb reklám megmutatása a felhasználónak.
  - **Felfedezés**: egy új reklám megmutatása a felhasználónak, hátha tetszik neki.
- Olajfúrás:
  - **Kizsákmányolás**: Egy meglévő helyen fúrás az olajért.
  - **Felfedezés**: Egy új helyen fúrás.
- Klinikai kezelés:
  - **Kizsákmányolás**: A bevált kezelés alkalmazása.
  - **Felfedezés**: Új kezelés kipróbálása.

A rabló probléma

A k-karú rabló problémája egy elméleti megerősítéses tanulás probléma. A játékos egy rablógépen játszik, amelynek k karja van.
Minden karhúzás után egy állandó eloszlásból választott jutalmat kap az ügynök. Az ügynök célja, hogy olyan politikát válasszon, ami az elvárt hozamot maximalizálja 1000 cselekvés vagy *időlépés* után.

A rabló probléma

Az ügynöknek számon kell tartania, mennyi a jutalom várható értéke, ha adott egy a cselekvés. Ez a $Q(s,a)$ állapot-cselekvés minőség függvény. A rabló problémában csak egy állapot van, ezért elég csak a cselekvésekhez tartozóan számon tartani:

$$q_*(a) = E\left[r_t | A_t = a\right]$$

A jutalom várható értéke:

$$Q_n = \frac{r_1 + r_2 + \ldots + r_{n-1}}{n-1}$$

A rabló folyamat modellje

A példában egy kétkarú rabló folyamat modellje látható. A modell egyetlen állapotot tartalmaz. az ügynök minden lépésben innen választhat, hogy melyik kart húzza meg. Ez a két cselekvéssel egyezik meg: a_1, a_2.

A jutalmak minden cselekvés után egy normál eloszlásból származnak, valamilyen μ_1 és μ_2 várható értékkel és 1 szórással: $r \sim N(\mu_1, 1)$.

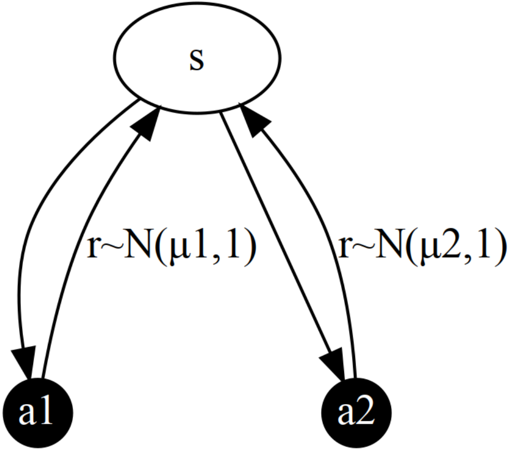

Algoritmus 1: Rabló játék

```
Q(a) ← 0 for a = 1 → k;                    /* Cselekvés minőségének függvénye */
N(a) ← 0 for a = 1 → k;                    /* Kar meghúzásainak a száma */
for t = 1 → max_t do
    p = random(0,1);                        /* Véletlen szám 0 és 1 között */
    if p > ε then
        a ← argmax_a Q(a);                  /* Legnagyobb ismert jutalom cselekvése */
    else
        a ← a ~ A;                          /* Véletlen cselekvés */
    end
    r ← env(a);                             /* Cselekvés végrehajtása a környezetben */
    N(a) ← N(a) + 1;                        /* Cselekvés számlálójának növelése */
    Q(a) ← Q(a) + 1/N(a) [r − Q(a)];        /* Q-érték frissítése */
end
```

Egy példa rabló

Hogy meg lehessen mérni a mohó és ε-mohó stratégiák teljesítményét, szükség van egy teszt rablóra. A példában szereplő egy 10-karú rabló. Minden karhoz tartozóan a jutalmak eloszlása Gauss-i eloszlást követ 1 varianciával, viszont nem 0 átlaggal.

Valamelyik karok nagyobb valószínűséggel járnak magas jutalommal mint a többi. Az ügynök feladata megtalálni melyik kartól remélhet nagyobb jutalmat. Ehhez szükség van arra, hogy végig próbálja őket.

A jutalmak eloszlása

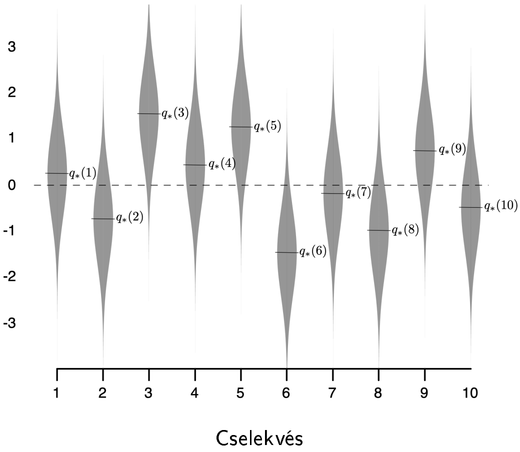

A futás teljesítménye

Az algoritmus 1000 időlépésen keresztül futott $\varepsilon = 0, \varepsilon = 0.01, \varepsilon = 0.001$ hiperparaméterekkel. Minél nagyobb a ε érték, annál nagyobb a felfedezés valószínűsége.

Mindegyik módszer megbecsülte az állapot-cselekvés minőség függvényt a rabló minden karára a mozgóátlagolás technikájával. A diagramon a várható jutalom mértékét mutatja az időlépések függvényében.

A mohó stratégia kezdetben gyorsabban javult mint a többi, de kisebb értékre konvergált a futásidő végére.

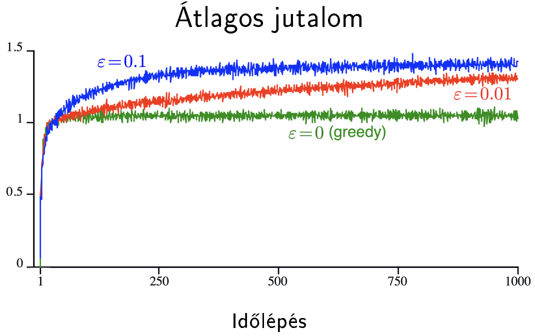

A futás teljesítménye

Az ábra azt mutatja, hogy a mohó módszer csak a feladatok mintegy 30%-ában találta meg az optimális műveletet. Az ε-mohó módszerek végül jobban teljesítettek, mert folytatták a felfedezést és javították az esélyüket az optimális művelet felismerésére.

Az $\varepsilon = 0.1$ módszer többet fedezett fel, és általában korábban megtalálta az optimális műveletet, de soha nem választotta ki azt több mint 91%-ban.

Az $\varepsilon = 0.01$ módszer lassabban javult, de végül mindkét teljesítménymérőn jobban teljesített.

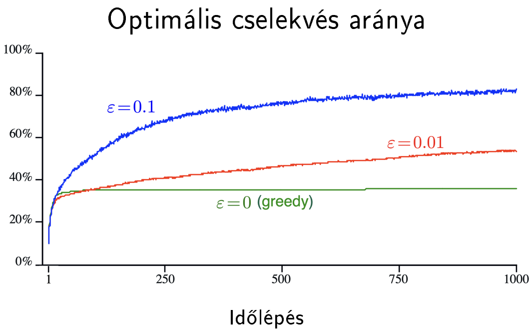

Dinamikus programozás alapjai

A dinamikus programozás egy gyűjtőfogalom olyan algoritmusokra amelyekkel kiszámolható az optimális politika *ha adott egy tökéletes környezeti modell egy Markov döntési folyamatként*.

A klasszikus dinamikus programozási algoritmusok ritkák a megerősítéses tanulásban mert egy tökéletes környezeti modellt feltételeznek és mert rendkívül erőforrás igényesek.

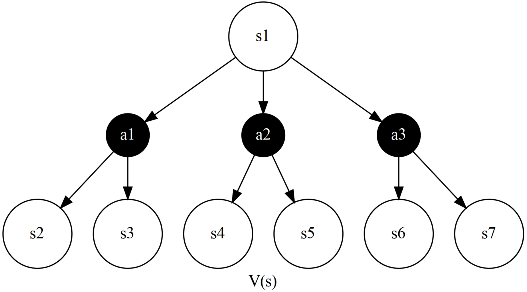

Dinamikus programozás alapjai

Dinamikus programozás

A DP algoritmusok a komplex problémákat alproblémákra bontják, majd a végső megoldást az alproblémák megoldásaiból állítják elő. Ehhez két feltételnek kell érvényesnek lennie:

- **Optimális alstruktúra**: Az almegoldásoknak felhasználhatóknak kell lenniük a probléma megoldására.
- **Átfedésben lévő alproblémák**: Bizonyos alproblémák megoldásait többször is fel lehet használni hasonló feladatok elvégzéséhez.

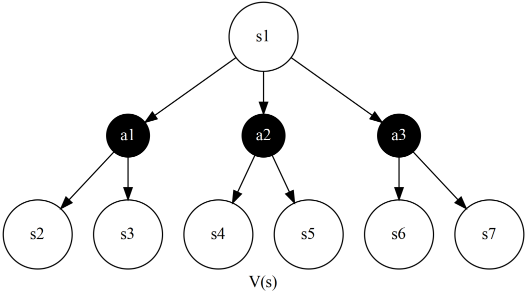

Példa dinamikus programozásra

A példa a Fibonacci számok kiszámításának dinamikus programozása. A Fibonacci számokat a következőképpen lehet definiálni:

Fibonacci sorozat

$$F_0 = 0 \,;\, F_1 = 1$$

és

$$F_n = F_{n-1} + F_{n-2}$$

Tehát a sorozat első pár tagja:

$$0, 1, 1, 2, 3, 5, 8, 13, 21, 34, 55, 89, 144$$

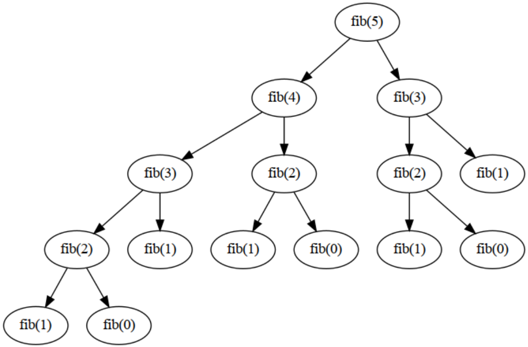

Dinamikus programozás az RL-ben

DP állapot-érték frissítési szabálya

$$V(s_t) \leftarrow E_\pi \left[r_{t+1} + \gamma V(s_{t+1}) \right]$$

- E_π: várható érték π politika alatt
- $V(s_t)$: cselekvés-érték függvény az aktuális s állapotban
- r_{t+1}: a jutalom a következő cselekvésért
- γ: diszkont faktor
- $V(s_{t+1})$ vagy s': cselekvés-érték függvény a következő állapotban.

A megerősítéses tanulásban a dinamikus programozás egy szélességi bejárásnak felel meg. Mivel az állapotok tere túlságosan nagy, ez gyakran nem vezet megoldáshoz.

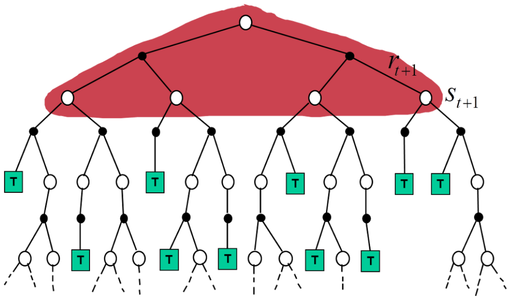

Markov döntési folyamatok dinamikus programozása

A Markov döntési folyamatok kielégítik a dinamikus programozás feltételeit.
Az értékfüggvény eltárolja és újra felhasználja a kiszámított megoldásokat: ez egy gyorsítótárként szolgál azoknak az információknak az MDP-ről, ami megadja, hogy mennyi a jutalom várható értéke egy s állapotból indulva:

$$v_\pi(s) = E_\pi\left[G_t | S_t = s\right] = E_\pi\left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \mid S_t = s\right]$$

A Bellman egyenlet megadja, hogyan kell lebontani az optimális állapot-érték függvényt két részre: a következő időlépés optimális cselekvése és az összes többi lépés optimális cselekvése:

$$v_\pi(s) = \sum_a \pi(a|s) \sum_{s',r} p\left(s', r | s, a\right) \left[r + \gamma v_\pi\left(s'\right)\right] \; minden \; s \in S - re$$

Dinamikus programozás felhasználásai

A dinamikus programozási eljárások akkor tudnak megoldani megerősítéses tanulási problémákat, ha adott a környezet dinamikája (az állapotok, az állapotátmeneti valószínűségek, jutalmak). Ezért két fő felhasználása van:

1. Politika kiértékelés

Ha adott egy $MDP(S, A, P, R, \gamma, s_0)$ és egy π politika, a feladat megtalálni π-hez tartozó v_π állapot-érték függvényt ahhoz, hogy meg lehessen mondani mennyire jövedelmező a politika.

2. Politika keresés

Ha adott egy $MDP(S, A, P, R, \gamma, s_0)$, a feladat megtalálni az optimális állapot-érték függvényt (v_π) és a hozzá tartozó π_* optimális politikát.

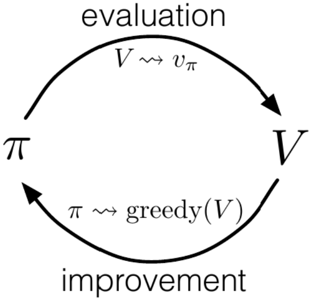

Politika iteráció

Miután egy π politika javult v_π segítségével annak érdekében, hogy egy π' jobb politikát eredményezzen ki lehet számítani $v_{\pi'}$ javított állapot-érték függvényt és felhasználni egy újabb javított politika, π'' kiszámítására. Ezáltal egy monoton javuló politika - értékfüggvény sorozatot eredményezve:

$$\pi_0 \xrightarrow{E} v_{\pi_0} \xrightarrow{I} \pi_1 \xrightarrow{E} v_{\pi_1} \xrightarrow{I} \pi_2 \xrightarrow{E} \dots \xrightarrow{I} \pi_* \xrightarrow{E} v_*$$

- E: Kiértékelés (evaluation)
- I: Javítás (improvement)
- v_*: Optimális állapot-érték függvény
- π_*: Optimális politika

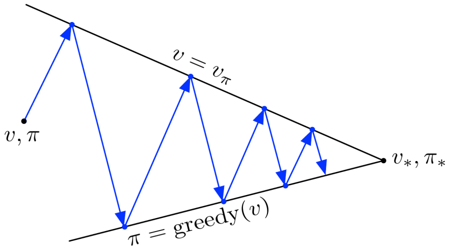

Algoritmus 2: Politika kiértékelése

```
while Δ > θ do
    Δ ← 0;                                              /* Hiba nullára állítása */
    for s ∈ S do
        v ← V(s);                                       /* Jelenlegi állapot-érték */
        V(s) ← Σ_{s',r} p(s', r, |s, π(s)) [r + γV(s')];  /* Új állapot-érték */
        Δ ← max(Δ, |v − V(s)|);                         /* Hiba kiszámolása */
    end
end
```

- Δ: $V(s)$ jelen állapot-érték és $V(s_{t+1})$ következő állapot-érték különbsége.
- θ: hibahatár: egy alacsony szám ami a becslés pontosságát adja.
- $p(s', r, |s, \pi(s))$: s' következő állapot és r jutalom valószínűsége ha adott s állapot és $\pi(s)$ cselekvés π politika szerint (a környezet dinamikája).

Algoritmus 3: Politika javítása

```
π_instabil ← false;                                   /* Politika instabilon indul */
while π_instabil do
    for s ∈ S do
        a ← π(s);                                        /* Jelenlegi cselekvés */
        π(s) ← argmax_a Σ_{s',r} p(s', r, |s, a)[r + γV(s')];   /* Új cselekvés */
        if a ≠ π(s) then
            π_instabil ← false;                    /* politika instabillá állítása */
        end
    end
end
return v ≈ v_*, π ≈ π_*
```

A politika ebben az esetben mohó, tehát úgy választja ki a cselekvést, hogy melyik következő állapothoz tartozik a lehető legnagyobb várható jutalom. Egy politika akkor számít stabilnak, amikor egyik lépésben sem változik a cselekvés.

Példa politika iterációra

Cél: a robotnak el kell jutnia a célhoz, miközben minél kevesebb üzemanyagot használ. A környezetben a következő változók érvényesek:

- Száraz kockák:
  - 1 időegység alatt megy végig rajta a robot. -1 jutalmat kap ha egy ilyen kockára lép.
  - A célállapotot mindig eléri, mert ilyenkor nem csúszik el.
- Kis tócsák:
  - 2 időegység rajta átjutni, tehát -2 jutalmat kap érte a robot.
  - A csúszás valószínűsége 0.4, ezért az idő 40%-ában nem éri el a célállapotot, hanem valamelyik másik lehetséges célállapotba csúszik át.
- Nagy tócsák:
  - 4 időegység alatt lehet rajta átjutni, ezért -4 jutalom jár érte.
  - A csúszás valószínűsége 0.6.

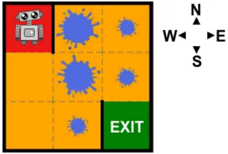

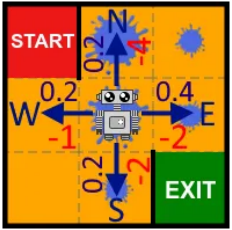

Példa politika iterációra

A robotnak a bal felső kockából kell a jobb alsóba eljutnia úgy, hogy a falakat megkerüli.

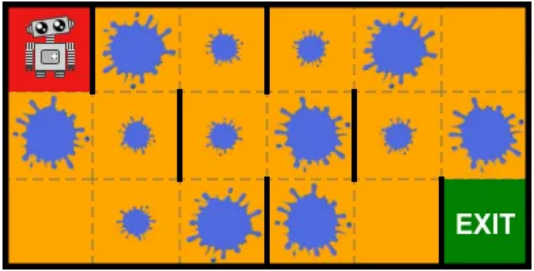

Példa politika iterációra

A kezdeti politika véletlenszerű és determinisztikus.

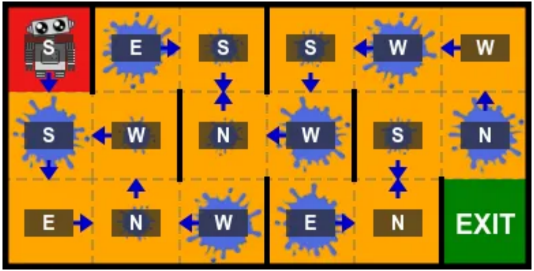

Példa politika iterációra

A $V(s)$ állapot értékek 0 értékkel indulnak.

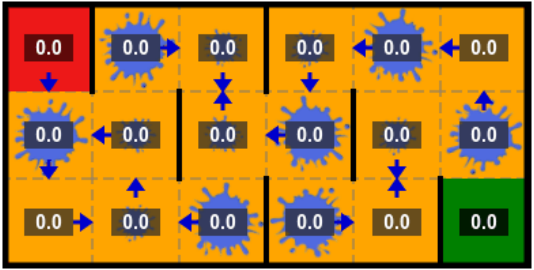

Példa politika iterációra

$\gamma = 0.9$ diszkont rátával a politika kiértékelés 75 iteráció alatt konvergál.

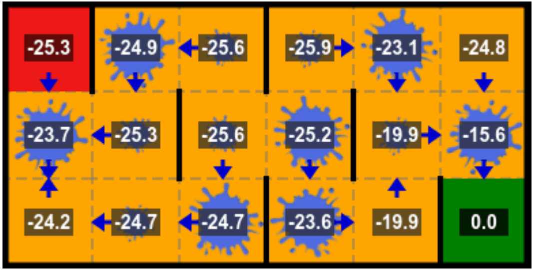

Példa politika iterációra

A következő iterációban a politika változik. A konvergálás 55 iteráció alatt megtörtént.

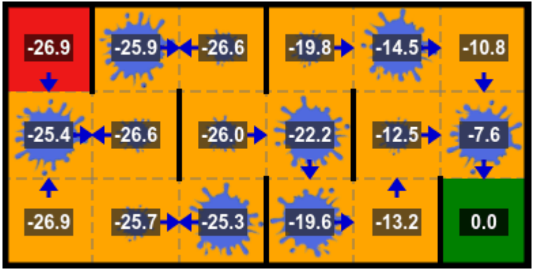

Példa politika iterációra

A következő futtatással 26 iteráció alatt konvergált.

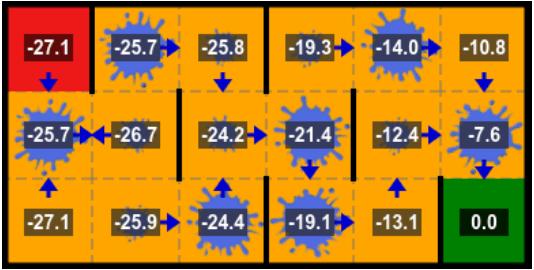

Példa politika iterációra

A következő futtatással 21 iteráció alatt konvergált.

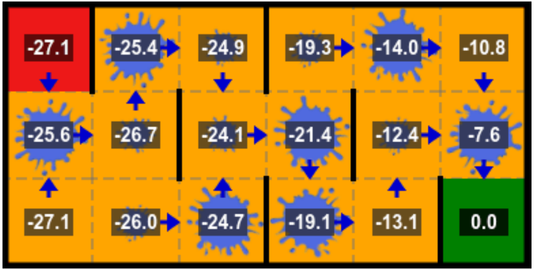

Példa politika iterációra

A következő futtatással 26 iteráció alatt konvergált.