

Üzleti Intelligencia

6. Előadás: Q -tanulás

Kuknyó Dániel
Budapesti Gazdasági Egyetem

2023/24
1.félév


- 1 Bevezetés
- 2 Függvény illesztés
- 3 Gradiens ereszkedés

- 1 Bevezetés
- 2 Függvény illesztés
- 3 Gradiens ereszkedés

Bevezetés a Q -tanulásba

A megerősítéses tanulásban a $Q_\pi(s, a)$ minőségfüggvény megadja, hogy mennyire jövedelmező az ügynöknek, ha s állapotban állva, a cselekvést végrehajtva majd onnan π politikát követve mekkora a várható hozam.

Ha adott minden állapotra és cselekvésre az optimális $Q(s, a)$ érték, onnan levezethető a π_* optimális politika, amelynek várható hozama maximális.



$$q_\pi(s, a) = E_\pi [G_t | s_t = s, a_t = a] = E_\pi \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s, a_t = a \right]$$

Q-tanulás: politikafüggetlen TD irányítás


A megerősítéses tanulásban az egyik nagy áttörést egy politikafüggetlen TD algoritmus kifejlesztése hozta el.

Ebben az esetben a becsült állapot-cselekvés minőség függvény, Q , közvetlenül becsüli meg q_* optimális állapot-cselekvés minőség függvényt a követett politikától teljesen függetlenül.

Q-tanulás

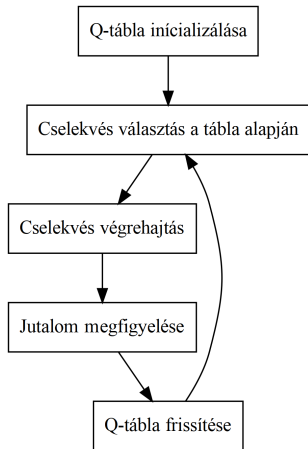
$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_{t+1} + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t) \right]$$

Az egyetlen különbség a SARSA algoritmusától, hogy a referencia a következő állapotból elérhető legjobb minőségű cselekvés értéke: $\max_a Q(s_{t+1}, a)$.



Q-tanulás eljárása

A Q-tanulás folyamata



Példa Q-táblára

	a_0	a_1	a_2	a_3
s_0	0.76	0.41	0.92	-0.14
s_1	-0.65	0.31	-0.07	0.55
s_2	0.23	-0.99	0.67	-0.43
s_3	-0.81	0.79	-0.58	0.17
s_4	0.62	-0.28	0.96	-0.72
s_5	-0.36	0.08	-0.51	0.64

A Q-tábla tárolja el a $Q(s, a)$ értékeket minden $s \in S$ és $a \in A$ párosra.

Algoritmus 1: Q -tanulás algoritmus $\pi \approx \pi_*$ megbecslésére

Input: α tanulási sebesség; $\varepsilon > 0$ hibahatár

```
 $Q(s, a) \leftarrow \text{random}()$  for  $s \in S, a \in A$ ;      /*  $Q$  értékek inicializálása */  
 $Q(s_T, \cdot) \leftarrow 0$ ;                        /* Terminális állapot 0-ra állítása */  
for  $i = 0 \rightarrow \max_i$  do  
     $s$  inicializálása;  
    while  $s \neq s_T$  do  
         $a \leftarrow \pi(s)$ ;      /* Cselekvés választása  $\pi$  szerint, pl.  $\varepsilon$ -mohó */  
         $a$  végrehajtása,  $r$  és  $s'$  megfigyelése;  
         $Q(s, a) \leftarrow Q(s, a) + \alpha \left[ r + \gamma \max_a Q(s', a) - Q(s, a) \right]$ ;  
         $s \leftarrow s'$ ;                                /*  $s$  frissítése */  
    end  
end
```

A politikát a Q -tábla határozza meg.

Dupla Q -tanulás

A kettős tanulás ötlete természetesen kiterjed a teljes MDP algoritmusaira. A Q -tanulásban a becsült Q -értékek torzítottak lehetnek, ha alacsony a minta számossága, vagy zaj van a rendszerben. Egy módja a Q -tanulás regularizálásának, ha egy helyet **két Q -táblát tart nyilván az algoritmus**, Q_1 -et és Q_2 -t.

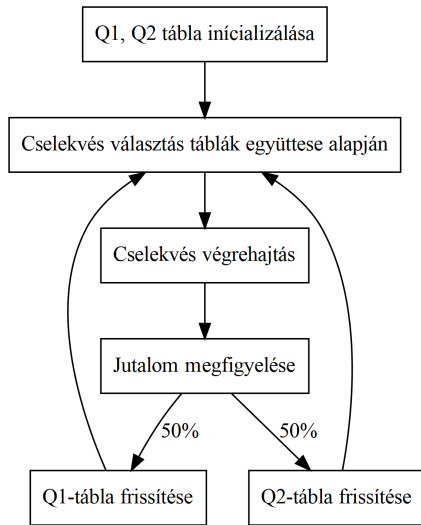
A Q -tanulással analóg dupla Q -tanulás nevű kettős tanulási algoritmus két részre osztja az időlépéseket, **minden lépésnél egy érmét feldobva**. Ha az érme fejre esik, a frissítés a következő:

$$Q_1(s_t, a_t) \leftarrow Q_1(s_t, a_t) + \alpha \left[r_{t+1} + \gamma Q_2(s_t + 1, \underset{a}{\operatorname{argmax}} Q_1(s_{t+1}, a)) - Q_1(s_t, a_t) \right]$$

Ha az érme pedig írásra esik, akkor ugyanez a frissítés Q_1 és Q_2 felcserélésével történik, így Q_2 frissül. A két közelítő értékfüggvényt teljesen szimmetrikusan kezeli az algoritmus. Például egy ε -mohó politika a dupla tanulás esetében az egyes cselekvési értébecslések **átlagára vagy összegére épülhet**.

Dupla Q -tanulás eljárása

Mivel két Q táblát kell nyilván tartania, az algoritmus memóriaigénye megkétszereződik. A becsült értékek viszont jóval torzítatlanabbak lesznek, mint az egyszeres Q tanulás esetében. A lépésenkénti számításigény nem növekszik az extra Q -tábla bevonásával.



end

- 1 Bevezetés
- 2 Függvény illesztés
- 3 Gradiens ereszkedés


Függvény illesztés alapjai

A függvény illesztés eljárása szerint valamely x **független változóból** vett minta alapján szeretnénk előre jelezni egy y **függő változó** értékét azért, hogy feltárja az adatpontok közötti mintázatokat.

Két eljárása ismert:

- **Regresszió:** tárgya egy folytonos változó
- **Osztályozás:** tárgya egy diszkrét változó

A függvény illesztés eredménye a **modell**.



Függvény illesztés alapjai


Az illesztett modell alakját és viselkedését a **paraméterei** határozzák meg, amelyek együttthatókként viselkednek a modell egyenletében. A lineáris modell egyenlete:

$$y_i = \theta_0 + \theta_1 x_i + \varepsilon_i$$

Ahol:

- θ_0 : az y tengely metszéspontja, vagy eltolás
- θ_1 : az egyenes meredeksége
- ε : a véletlen hiba, amit a modell nem tud előre jelezni

$\theta = [\theta_0, \theta_1, \dots, \theta_n]$ a paraméterek vektora.




Függvény illesztés több paraméterrel

Függvényt lehetséges nemlineáris adatokra is illeszteni. Ebben a példában a minta adatpontok kvadratikusak, **nem írhatók le egy lineáris egyenlettel**. A modellnek ebben az esetben 3 paramétere van: θ_0 , θ_1 és θ_2 . Az illesztett modell egyenlete:

$$y = 1.78 + 0.93x + 0.56x^2$$

Tehát ebben az esetben $\theta_0 = 1.78$, $\theta_1 = 0.93$ és $\theta_2 = 0.56$.




- 1 Bevezetés
- 2 Függvény illesztés
- 3 Gradiens ereszkedés

A költségfüggvény

A modell illesztő algoritmusok mindegyike úgy találja meg az optimális függvényt, hogy valamilyen költségfüggvényt minimalizál. A leggyakoribb ilyen költségfüggvény az **átlagos négyzetes hiba**:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - f(x)_i)$$

- y_i : Megfigyelt adatpont
- $f(x)_i$: Modell által adott becslés



A gradiens

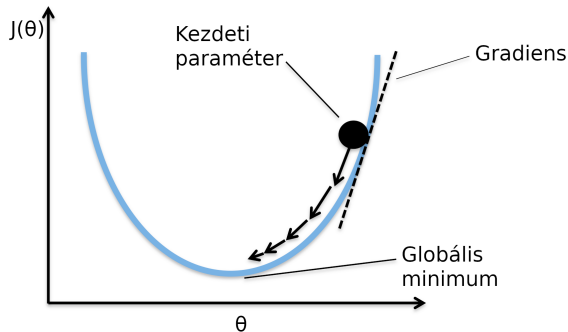
A függvény illesztés célja, hogy megtalálja azt a modellt, ami a legjobban illeszkedik az adatpontokra, tehát **minimalizálja a költségfüggvényt** (MSE).

Gradiens

Olyan vektor, amely megmutatja hogyan változik a függvény, és megadja a legnagyobb változás irányát minden dimenzióban.

$$df = \nabla f * dx$$

A gradiens segítségével meg lehet határozni, merre és mennyivel érdemes változtatni a paramétereket a célfüggvény értékének csökkentése érdekében.



Bevezetés
○○○○○○○○○○

Függvény illesztés
○○○

Gradiens ereszkedés
○○○●