Üzleti Intelligencia

Megerősítéses tanulás - beadandó feladatok

2023

A feladatok 1-3 skálán vannak osztályozva nehézség szerint, ahol 1 a legkönnyebb és 3 a legnehezebb. A feladatok véletlenszerűen sorsolódnak ki a 6. gyakorlaton. A feladatok beadása Coospace felületen történik, ahol csak egy linket kell beküldeni, ami a feladatot megvalósító Git tárhelyre mutat. Késő beadás nem lehetséges, a dátum beadásakor feltöltött anyagok fognak leosztályozásra kerülni. Minden további információ a tantárgyi útmutatóban és az órán elhangzottakban találhatóak.

1 Duna

Az ügynök Esztergomban áll, és olyan gyorsan kell eljutnia Pestre, amennyire csak lehet. Két út van, amelyekkel elhagyhatja a várost, az 10-es és 11-es út Mindkét út különböző helyre vezet.

Miután megérkezett Budára, két hídon juthat át a Duna folyón, hogy eljusson Pestre. A forgalom kiszámíthatatlan, így előfordulhat, hogy a hídon amit választott forgalmi dugó alakul ki.

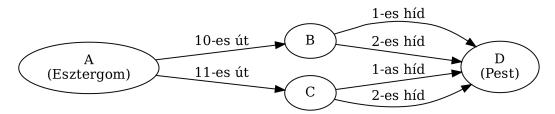
Néha pedig átirányítódik a másik hídra annak ellenére, hogy a másik útvonalat vagy hidat választotta.

A cél az, hogy olyan stratégiát találjon az ügynök, ami a leghamarabb eljuttatja a céljához. A jutalmak a negatív időt jelentik, amelyre szüksége van az adott út/híd átlépéséhez

Az $A,\,B,\,C$ állapotokhoz és minden cselekvéshez a jutalom a következőképpen számolódik ki:

$$R(s,a) = \begin{cases} \text{Ha nincs dug\'o} & R(s,norm) \\ \text{Ha dug\'o van} & R(s,dug\'o) \end{cases}$$

Előfordulhat, hogy az ügynök választ egy irányt, de átirányítják a másikra. Tehát ha P(s,a,s')=0.9, tehát 90% valószínűséggel abba az irányba megy, amit választott, de 10% valószínűséggel átirányítják a másik útra.



A környezet dinamikája (P(s, a, s'), R(s, a, s')):

$$\begin{split} &P(A,10,B) = 0.79,\, P_{\rm dug\acute{o}}(A,10,B) = 0.9,\, R_{\rm dug\acute{o}}(A,10,B) = -60,\, R_{\rm norm}(A,10,B) = -21\\ &P(A,11,C) = 0.89,\, P_{\rm dug\acute{o}}(A,11,C) = 0.56,\, R_{\rm dug\acute{o}}(A,11,C) = -44,\, R_{\rm norm}(A,11,C) = -1\\ &P(B,1,D) = 0.84,\, P_{\rm dug\acute{o}}(B,1,D) = 0.43,\, R_{\rm dug\acute{o}}(B,1,D) = -20,\, R_{\rm norm}(B,1,D) = -4\\ &P(B,2,D) = 0.7,\, P_{\rm dug\acute{o}}(B,2,D) = 0.84,\, R_{\rm dug\acute{o}}(B,2,D) = -40,\, R_{\rm norm}(B,2,D) = -11\\ &P(C,1,D) = 0.98,\, P_{\rm dug\acute{o}}(C,1,D) = 0.75,\, R_{\rm dug\acute{o}}(C,1,D) = -65,\, R_{\rm norm}(C,1,D) = -5\\ &P(C,2,D) = 0.77,\, P_{\rm dug\acute{o}}(C,2,D) = 0.53,\, R_{\rm dug\acute{o}}(C,2,D) = -58,\, R_{\rm norm}(C,2,D) = -10 \end{split}$$

1.1 Dinamikus programozás

Oldja meg a problémát dinamikus programozással. Ehhez tartozóan implementálja a politika iteráció eljárását (politika kiértékelés, politika javítás). Futtassa a szimulációt adott konvergencia kritériumig. Mutassa meg, hogy az ügynök megtanulta optimalizálni a jutalmat. Írja le röviden az eljárás elméleti alapjait és a saját tapasztalatait egy Jupyter markdown cellában

1.2 Sztochasztikus becslés

Oldja meg a problémát sztochasztikus becsléssel. Ehhez tartozóan implementálja a Monte Carlo és időbeli különbségek politika keresési eljárásait. Futtassa a szimulációt adott konvergencia kritériumig. Mutassa meg, hogy az ügynök megtanulta optimalizálni a jutalmat. Írja le röviden az eljárás elméleti alapjait és a saját tapasztalatait egy Jupyter markdown cellában